

ENTERPRISE AI & DATA STRATEGY

Arquitectura RAG

Open Source y Cloud Native
para la Mina "Yana Killa"

Jean Pierre Mandujano

Founder · Deep Skill





Jean Pierre Mandujano

Founder • Deep Skill

Construye software e IA aplicada para minería e industria. Antes, CTO y cofundador de Deep Pit Technology, adquirida por STRACON Technologies en 2022, y ex Tech Lead / Engineering Manager en Scotiabank Perú.

Formación en ingeniería geológica en la UNI: conoce de primera mano los documentos de los que trata esta charla.

ON-PREM

RAG

AI

PLATFORM

El pedido

UNA MINA, UN ARCHIVO, UNA REGLA

**40 años
en PDF**

Estudios, normas,
expedientes

**Un dato
de 2014**

Alguien lo necesita hoy

**Nada sale
de la red**

Requisito no negociable

**¿Cuál es el sistema más pequeño
que resuelve esto?**

Lo primero que uno intenta

PEGAR TODO EN EL PROMPT

```
system: Eres un asistente técnico.
```

```
user: [47 PDFs]  
      ¿Qué dice la norma sobre X?
```

**El modelo
no recuerda
nada.**

Ventana

Costo


Citas

Escala

Se rompe por cuatro lados.

Recuperar antes de generar

LA ANATOMÍA MÍNIMA



**El modelo no es el sistema.
Es el último paso del sistema.**

Todo lo que se puede autohospedar ocurre antes.

Significado como coordenadas

EMBEDDINGS

"drenaje ácido de roca"
→ [0.021, -0.118, ...]

"generación de aguas ácidas"
→ [0.019, -0.121, ...]

Cero palabras en común.
Vectores casi idénticos.

bge-m3

1024 dimensiones
Español e inglés

CPU · 2 GB

Sin GPU. Sin API.

Primera decisión de portabilidad

Lo semántico no basta

BÚSQUEDA HÍBRIDA

PZ-14B

no se parece
a nada

BM25

Literal.
Encuentra el código.

Vectorial

Semántico.
Encuentra el concepto.


RRF

Fusiona por rango.
 $k=60 \cdot \text{top 8 de 20}$.

Dos búsquedas en paralelo. Una sola lista.

El cuello de botella no es el modelo

LA INGESTA



**Sin capa
de texto**

el pipeline la OCRea solo

**Capa de texto
basura**

entra tal cual al índice

```
heading: "i /{Ene@PUCALLPAS®MUNICIPALIDAD PROVINCIAL oe"
```

Chunk real del índice de producción: el OCR previo del PDF, tomado como título de sección.

Que no invente

GROUNDING Y CITAS

Responde SÓLO con los pasajes recuperados. Si no están, dílo.

Cada afirmación → marcador [^N]

citations[]

archivo + página
validado en el código

La cita se verifica en el código.

Lo no verificable se ve como no verificable. Nunca se fabrica un enlace.

La superficie que nadie mira

SEGURIDAD

El atacante no te escribe. Sube un PDF.

Inyección indirecta

El documento trae las instrucciones

Permisos

El retrieval debe respetar los ACL

Qué sale

Pregunta y pasajes viajan al proveedor

Primero validar, después mudar

POR QUÉ EMPEZAMOS EN LA NUBE

Comprar hierro para validar

es la forma más cara
de equivocarse

t3.medium

2 vCPU · 4 GB RAM

30 GB gp3

Sin GPU

**Nada de lo elegido
nos ataba a la nube.**

Contratos, no servicios

LAS DECISIONES

Índice

SQLite + sqlite-vec + FTS5

Embeddings

bge-m3 en CPU

Modelo

LiteLLM

Documentos

Disco local · contrato S3

Despliegue

Docker Compose

Cloud native no es Kubernetes.

Cuánto hierro hace falta

EL NÚMERO

4 GB de RAM. Sin GPU.

SI ADEMÁS QUIERES EL MODELO ADENTRO

8B q4

9.5 GB

GPU de 12 GB

32B q4

30 GB

GPU de 32 GB

70B q4

57 GB

2 × 32 GB

Cuando algo se cae

DEMO Y CONTINGENCIA

Demo

Pregunta → respuesta
con cita → el PDF
en el párrafo exacto

Medido en producción:

440 ms el retrieval · 1,7 s al primer token

Plan B

Sin internet:
modelo local

Plan C

Modelo caído:
búsqueda con citas

**Si se cae el proveedor y tu app muere,
no es un sistema: es un cliente de una API.**



Gracias

¿Cuál es el sistema más pequeño que resuelve tu problema?

Contacto

jeanpierre.mandujano@deepskill.space
linkedin.com/in/manduinca

#OODLima · #DevOpsDaysLima