

IA Y ESTRATEGIA DE DATOS

CI/CD para Agentes de IA

Desplegando Agentes con ADK en Producción

Henry Keniding Tarazona

AI Agent Engineer · Interbank





Henry Keniding Tarazona Lazaro

Software Engineer & AI Agent Engineer · Interbank

Software Engineer en Interbank especializado en microservicios, cloud e IA Generativa aplicada a banca. AI Agent Engineer automatizando procesos con LLMs y Google ADK. Líder de IA en ML Laboratory (DSC UTP).

IA

ADK

GCP

CI/CD

¿De qué vamos a hablar?

Un recorrido teórico, con demo en vivo

De la cultura DevOps al despliegue completo de un agente con **ADK**.

DEVOPS

GITHUB

ADK

TESTING

CI/CD


GCP

CLAUDE

 Interbank



2024 - PRESENTE



vs. MLOps

AGENT OPS

Evolución de MLOps para agentes autónomos y LLMs

Crónicas DevOps

El problema



Construir $\neq$ Operar

Que funcione en una demo no basta: en producción necesita versionado, pruebas y observabilidad — lo que **CI/CD ya resuelve para software tradicional**.

PROMPT

VERSIÓN

TESTS

MONITOREO

ROLLBACK

CONFIANZA

PRODUCCIÓN

DOS DISCIPLINAS

CULTURA

DevOps

Cultura, automatización y medición que rompe los silos entre desarrollo y operaciones.

Práctica

CI/CD

Prácticas que automatizan build, pruebas y despliegue para entregar software con confianza.



TRES NIVELES DE AUTOMATIZACIÓN

INTEGRACIÓN CONTINUA (CI)

- Cada cambio se integra y se prueba automáticamente varias veces al día.

ENTREGA CONTINUA


- El artefacto queda listo para producción; el paso final requiere aprobación manual.

DESPLIEGUE CONTINUO

- Si todas las pruebas pasan, el cambio llega a producción sin intervención humana.

DEVSECOPS

- Seguridad automatizada en cada etapa: escaneo de dependencias y gestión de secretos.



El motor de automatización

Vive en el mismo repositorio que el código: un evento dispara un workflow compuesto de jobs y steps, ejecutados en un **runner efímero**.

WORKFLOW

JOB

STEP

ACTION

RUNNER

SECRET

EVENTO

Google Cloud: el destino del pipeline

BUILD

REGISTRY

RUN

SECRETS


IAM

OIDC

LOGS

De la imagen al servicio en producción

La imagen del agente se construye, se publica versionada y se despliega a Cloud Run, con autenticación federada y sin claves estáticas:
`gcloud run deploy`



Autenticación sin claves estáticas

DOS ENFOQUES

Enfoque antiguo

Service Account Key

Clave JSON de larga duración guardada como secreto. Si se filtra, el acceso queda comprometido.

Enfoque actual

Workload Identity Federation

GitHub emite un token OIDC de corta duración; GCP lo intercambia por credenciales temporales.



POR QUÉ GANA WORKLOAD IDENTITY FEDERATION

SIN CLAVES ESTÁTICAS

- No hay JSON de service account almacenado en GitHub Secrets.

CREDENCIALES TEMPORALES

- Se generan por cada ejecución del workflow y expiran solas.

ACCESO ACOTADO

- Se puede limitar por repositorio, rama o evento específico.

MISMO PATRÓN EN TODOS LADOS

- Claude Code GitHub Actions usa el mismo mecanismo para autenticarse.

Claude dentro del propio flujo de CI/CD

MENTIÓN

REVIEW

PR

ISSUE

SKILL

CLAUDE.MD

OIDC

IA operando el propio pipeline

No es el agente que se despliega: es un colaborador más dentro del workflow, que revisa código y responde en pull requests al mencionar **@claude**





TIPOS DE AGENTE

Razonamiento

LlmAgent

Su comportamiento lo gobierna un modelo de lenguaje: decide qué herramienta usar y en qué orden.

ADAPTATIVO

Orquestación

Workflow Agents

SequentialAgent, ParallelAgent y LoopAgent orquestan sub-agentes en un orden predecible.

DETERMINISTA

COMPONENTES CLAVE

TOOLS

- Funciones e integraciones que el agente invoca para actuar sobre el mundo exterior.

SESSIONS & STATE

- Contexto conversacional e historial de eventos durante una sesión activa.

MEMORY

- Información que el agente retiene entre múltiples sesiones, no solo una conversación.

MODELS

- Capa intercambiable de modelo: Gemini, Claude u otros, vía LiteLlm.

¿Qué significa “testear” un agente de IA?

TEST TRADICIONAL vs EVALUACIÓN

CI clásico

Test de software tradicional

Mismo input, mismo output:
assert(resultado == esperado) es suficiente.

DETERMINISTA

CI para agentes

Evaluación de un agente de IA

El mismo prompt puede generar respuestas distintas pero válidas: se necesitan umbrales, no igualdades.

PROBABILÍSTICO



CAPAS DE EVALUACIÓN

TOOL-CALLING

- ¿El agente elige la herramienta correcta y arma bien sus parámetros?

TRAYECTORIA

- ¿Qué secuencia de pasos siguió el agente para llegar a la respuesta?

LLM-AS-JUDGE

- Otro LLM puntúa la respuesta contra un rubric cuando no hay un valor exacto que comparar.

SEGURIDAD

- ¿Reveló información indebida? ¿Es robusto ante prompt injection?

El pipeline completo, de punta a punta



DEV

CI

BUILD

EVAL

PUBLICAR

DESPLEGAR

OBSERVAR


Un solo flujo, nueve etapas

Desde el desarrollo local con ADK hasta producción: build, evaluación automatizada, publicación y despliegue federado a Cloud Run, cerrando el ciclo con **observabilidad continua**.

DESARROLLO Y CI



PUBLICACIÓN Y PRODUCCIÓN





Construir es fácil.

Operarlo con disciplina, no.

La idea clave

Operar un agente con la misma disciplina, trazabilidad y velocidad que cualquier otro servicio crítico.



Gracias

Conversemos

Información de contacto

Email: kenidingh@gmail.com
LinkedIn: [/in/henry-tarazona](https://www.linkedin.com/in/henry-tarazona)

Únete a la conversación: [#DevOpsDaysLima](https://twitter.com/DevOpsDaysLima)

QR

