

- **ESTRATEGIA DE IA**

ENTRENAR EN LA NUBE, DESPLEGAR EN CASA

Estrategia empresarial híbrida para modelos predictivos y generativos

Francisco Lopez

Director de Arquitectura Risk & Compliance Royal Bank of Canada



29 de julio de 2025

Un banco entrenó su propio foundation model

ATOM

Asynchronous
Temporal Model · RBC
Borealis

MILES

de millones de
transacciones de clientes,
en su perímetro

2

sistemas en
producción: crédito y
Avion Rewards

2027

meta pública: CAD 700
a 1.000 millones por IA

No es un laboratorio de investigación ni una big tech. Es un banco, sobre sus propios datos. Comunicado público de RBC, 29 de julio de 2025.

¿Quién es RBC?

Royal Bank of Canada — el banco más grande de Canadá.

19+

millones de clientes

101.000+

empleados

PARA DIMENSIONARLO

BCP: 16 millones

de clientes · Memoria Integrada 2025

La cifra del BCP integra Yape; la de RBC es banca tradicional. Mismo orden, no idénticas.

No es Google. Es un banco.

Con sus sistemas core, sus reguladores y sus comités, igual que ustedes. Por eso su caso es replicable acá.

Fuentes: comunicado público de RBC, julio de 2026 · Memoria Integrada BCP 2025 (16 millones de clientes, 20.700 colaboradores).

El agente razona; no adivina

Un médico sabe medicina. No sabe la hemoglobina de este paciente: la pide.



ESCENARIO

Una hipoteca pedida a las nueve de la noche, decidida y explicada en minutos. Proyección, no un caso publicado.

Y no todo es generativo

GENERATIVO



extraer documentos

esto sí es un LLM



consultar normativa

esto sí es un LLM

PREDICTIVO



verificar ingresos

modelo tabular, no un LLM



evaluar riesgo crediticio

modelo tabular, no un LLM

Entrenados sobre transacciones,
probablemente llevan años en producción —
desde antes de todo esto. Lo nuevo es que hoy
se exponen como MCP.

El modelo decide. El LLM explica.

Un score determinista se audita, se versiona y se le explica a un regulador. Una estimación de un LLM, no.

Dos planes, no uno

PLAN GENERATIVO

Interpretar y redactar

- agentes
- asistentes
- recuperación
- resumen
- interpretación

Un modelo generativo no reemplaza uno de riesgo. Lo llama.

PLAN PREDICTIVO

Decidir con números

- riesgo
- propensión
- fraude
- demanda
- precios

Lo que decide plata todos los días.

**Orquestar se demuestra en una tarde.
Sostenerlo en producción, no.**

El plan generativo: una capa, y los modelos detrás

No expongan los modelos directamente. Pongan una capa por delante.



Capa de gobierno — AI gateway

Una decisión de arquitectura que vale más que la elección de modelo.

autenticación

enrutamiento

DLP y datos sensibles

registro de prompts

filtros

control de costo



Modelos comerciales

Para lo genérico, que es la mayoría de los casos.



Modelos propios, en casa

Para lo que toca datos que no pueden salir: pagos, fraude, datos de cliente.

↔ **Eso es exactamente lo que es ATOM**

El moat son los datos

El modelo se está volviendo commodity. Sus datos, no.

EL MODELO

↓ **se está commoditizando**

Los modelos de pesos abiertos cierran la brecha cada trimestre. Esa carrera no la van a ganar, y tampoco necesitan correrla.



TUS DATOS

Su historial transaccional, sus decisiones de riesgo, su operativa.

Lo único que ningún competidor puede replicar.

ATOM se entrenó sobre datos que solo ese banco tiene. Ese es el punto entero.

La matriz de decisión

Dos ejes: qué tan confidencial es el dato, y qué tan específica es la tarea.



El error no es elegir mal la herramienta. El error es tener una sola.


“

Los datos confidenciales se quedan bajo tu control. El conocimiento público puede viajar.

La regla de esta charla

Una arquitectura de datos para IA y ML

Hasta almacenamiento es la arquitectura de datos que ya conocen. Lo que sigue, no.



El feature store alimenta las dos vías: features históricas al entrenamiento, y features en línea directo al serving.

Una entrega tablas a personas. Esta entrega modelos.

Las mismas capas, distintas tecnologías

El diagrama no cambió. Solo le puse nombres propios debajo.



Lo que cambia son los logos. La arquitectura, no.

Busquen su propio stack acá adentro: casi seguro ya tienen la mayoría de estas casillas llenas, con una herramienta u otra.

El feature store es la fuente única de verdad

Por eso el dato es el moat: de una arquitectura gobernada sale el feature store.



Un solo origen gobernado. Cuatro formas de consumirlo. Cero copias sin control.

Tres etapas desacopladas

Entre las tres etapas viajan solo dos objetos inmutables. Nada más cruza.



El perímetro no es un edificio. Es dónde deciden poner el control.

¿Por qué RBC despliega en casa?

La respuesta no es compliance.



Invirtieron en una granja de GPUs, y al volumen de inferencia que manejan, la cuenta les sale.
Es una decisión de costo. No un principio.


EL GOBIERNO NO SE LO DA EL EDIFICIO

Se lo dan la cadena de custodia y la imagen inmutable — y esas dos cosas funcionan igual en AWS, en Azure o en su datacenter.

Si ustedes no tienen esa granja —y casi nadie la tiene— desplieguen en la nube. La arquitectura no cambia ni una línea.

¿Dónde se despliega, en concreto?

Acá está, y es más aburrido de lo que parece: la misma pila a los dos lados.



Los manifiestos son los mismos.

El InferenceService que escriben para su clúster corre igual en EKS. La ubicación es una decisión de costo, no de arquitectura.

Lo que sí cambia: cómo se reparte la GPU entre equipos, y cómo se resuelve la identidad contra sus sistemas corporativos. Eso no es portable.


Un modelo necesita los tres mundos a la vez

Ustedes viven en uno. Su equipo de datos, en otro. Sus científicos de datos, en el tercero.

DevOps

CI/CD, contenedores,
observabilidad, despliegue

Tres equipos, tres backlogs, tres jefes distintos — y un artefacto que los necesita a los tres al mismo tiempo.



Ingeniería de datos

pipelines, feature store,
gobierno, calidad

Machine Learning

entrenamiento, evaluación,
deriva, reentrenamiento

Un modelo en producción no respeta un organigrama.

MLOPS

LLMOps no es una disciplina aparte: es MLOps cuando lo que adaptan es un foundation model.

	DevOps	EL MISMO CICLO	
		MLOps modelo predictivo	LLMOps foundation model adaptado
Entrada	código	una tabla de features	un corpus de texto
Qué versionas	código	código · datos · modelo · entorno	+ modelo base · set de evaluación
Qué prueba	tests deterministas	evaluación estadística, por segmentos	evals versionados y comparables
Qué se degrada solo	nada	el modelo, por deriva de datos	+ el modelo base cambia debajo tuyo

LO QUE VERSIONAN

DevOps: una cosa. MLOps: cuatro. LLMOps: seis.

El agente del principio no es una tercera columna: es una aplicación que consume las dos.
Por eso una demo es una tarde y esto no: la demo no tiene ninguna de estas cuatro filas resuelta.

La cadena de custodia

```
$ trace --from
```

```
resultado_produccion 1 ·
```

```
feature_store_build_id 2 ·
```

```
training_snapshot_id 3 ·
```

```
model_version_id 4 ·
```

```
scoring_snapshot_id 5 ·
```

```
inference_run_id
```

construcción del feature store

snapshot con el que se entrenó

← **aquí vive el gate de aprobación de riesgo de modelo**

snapshot con el que se

puntuó

la ejecución concreta de inferencia

Con estos cinco: qué modelo lo produjo, con qué datos, aprobado por quién, en qué fecha.

Sin llamar a nadie. Sin abrir un ticket. Sin depender de que alguien se acuerde.

Esto no es una opinión aislada

No es un banco haciendo algo raro.

JPMorgan

Capital One

RBC

**Commonwealth
Bank**

HSBC

**Cinco bancos globales, cinco estrategias distintas,
el mismo patrón de fondo.**

Y despliegan en sitios distintos, según lo que a cada uno le sale a cuenta.

De fuente pública. Sin cifras añadidas por banco.

RBC es enorme — pero no es único, ni perfecto

RBC NO EMPEZÓ ESTO EN 2025

Empezaron hace más de diez años — organizando sus datos, formando talento, construyendo capacidad de investigación.

Y CON TODO ESO, SIGUEN TENIENDO LOS MISMOS PROBLEMAS QUE TODOS

datos en silos

equipos que no se hablan

modelos que nadie sabe cómo se entrenaron

No es una empresa que lo tiene resuelto. Es una que decidió empezar hace diez años.

Gobierno no es freno

Frena cuando es manual. Con plataforma, la evidencia se genera sola.

SIN PLATAFORMA



Cada modelo negocia su aprobación desde cero, reconstruyendo evidencia a mano. Cada parada naranja es un mes de calendario que nadie planificó.

CON PLATAFORMA



La evidencia se genera sola, como subproducto de ejecutar. La aprobación revisa, no reconstruye. Un solo carril continuo, del primer commit al modelo en producción.



El gate deja de ser una pared y pasa a ser un semáforo.

Y aquí, en esta región

Las empresas acá ya tienen arquitectura de datos.

- ✓ data lakes
- ✓ warehouses
- ✓ equipos de analítica
- ✓ pipelines corriendo todas las noches

EL DIAGRAMA DE HACE DIEZ MINUTOS

Fuentes

Ingesta

Almacenamient

Feature Store — la casilla que falta

Entrenamiento

Serving

La mayoría de esas casillas, ustedes ya las tienen llenas.

La materia prima está. Lo que falta no es infraestructura.

La pregunta con la que los quiero dejar



¿Cuál es su hoja de ruta de inteligencia artificial?

¿Tienen los dos planes, o solo el generativo?

¿Es dar licencias de Copilot al equipo? Eso está bien: eso les va a dar eficiencia.

¿O es una hoja de ruta que les dé ventaja competitiva?

Los datos confidenciales se quedan bajo su control. El conocimiento público puede viajar. Y el moat no es la tecnología.

La eficiencia se compra. La ventaja competitiva se construye



GRACIAS

Entrenar en la Nube, Desplegar en Casa

CONTACTO

Francisco Lopez Director de Arquitectura Risk
& Compliance - Royal Bank of Canada
[linkedin.com/in/francisco-lopez-valenzuela](https://www.linkedin.com/in/francisco-lopez-valenzuela)

PRÓXIMA CHARLA

«El plano» Cómo se construye la
plataforma que hoy solo vimos por
fuera.