

Enterprise AI & Data Strategy

De MVP a producción con Vertex AI Search

Lecciones reales de un asistente RAG universitario

Alan García Sánchez · Coordinador innovación digital UPCH

Paulo Costa Mondragon · Data Science & Backend



Matrícula: miles de consultas, pero cero aprendizaje



Tres canales en paralelo

Correo, WhatsApp y atención presencial. Ninguno compartía registro con los otros.



Solo en horario de oficina

La matrícula no respeta el horario administrativo.



Nada quedaba en un solo lugar

La respuesta existía; el dato no. Imposible saber qué se preguntaba más ni dónde mejorar.

Canales tradicionales, pero sin trazabilidad centralizada de las consultas.

Rápido de construir, confiable de responder



Cada conversación → datos

El objetivo: convertir la atención en insights para mejorar el servicio de forma continua.



Respuestas confiables y trazables

Fundamentadas en la base de conocimiento, con fuente citada. Menos alucinaciones, menos sesgo.



Escalar a humano cuando toca


El bot resuelve lo frecuente; los casos sensibles se derivan a un agente humano.

Restricción clave: tiempo. La matrícula no espera a que termines tu pipeline.

Tanobot: asistente RAG institucional

Asistente virtual académico que atendió consultas de estudiantes sobre matrícula y cronograma académico durante el proceso de matrícula 2026-I.

- Responde con fuentes de la base de conocimiento oficial.
- Mantiene contexto de la conversación.
- Deriva a un agente humano cuando el caso lo requiere.
- Registra cada interacción para análisis posterior.



El valor migró al juego



AÑOS 90

Cada estudio escribía render, física y audio antes del juego. En IA: chunking, embeddings, vector DB, retrieval, ranking antes del producto.

HOY

Usas Unity o Unreal y te concentras en el juego. En IA usas **Vertex AI Search** como motor RAG y te concentras en el **producto y en tus usuarios**.

Pipeline RAG

RAG tradicional



Construir

Ocho repos, ocho contratos de datos, ocho formas de fallar.

Operar

Reprocesos, alertas, y una migración cada vez que cambia el modelo de embeddings.

Pagar

Cómputo de indexado y almacenamiento vectorial, encendidos todo el mes.

El pipeline

Pipeline RAG



seis piezas se colapsan en una




Ingesta, OCR, indexado, retrieval, ranking y grounding: resueltos por el servicio.

Resultado: time-to-production de meses a semanas.

Primero el camino corto: RAG gestionado

Antes de escribir un pipeline propio, probamos el camino más corto: **RAG gestionado con Vertex AI Search**.


- 1 Documentos oficiales en Cloud Storage**
Reglamentos, calendario académico y Q&A de matrícula en PDF.
- 2 Data store + app de búsqueda**
Indexado y respuestas generativas sin infraestructura propia.
- 3 Preguntas reales en el preview**
Las dudas que ya llegaban a la oficina de registros académicos, tal como las escriben.
- 4 Criterio para continuar: la cita**
Cada respuesta apunta al documento y la página de donde sale.



Primera prueba en el widget de Vertex AI Search: respuesta generativa y fuentes con número de página.


Prototipamos primero; simplificamos después

LO QUE CONSTRUIMOS



Interfaz completa: FAQ lateral, chat a pantalla entera, fuentes bajo cada respuesta y encuesta al cerrar.

LO QUE QUEDÓ



Widget embebido en el portal. El consentimiento se acepta antes de la primera pregunta.

Por qué el widget alcanzó

Embed con lista de dominios

CORS controlado desde el panel, no en el código.

Apariencia y copy sin deploy

Color, posición, títulos y mensaje de bienvenida.

Términos antes de chatear

Política de privacidad como requisito, no como nota al pie.

La lección: un producto configurable sirve para más de un requerimiento.



De la idea a producción ~21 días



Cuatro razones técnicas, un argumento de negocio

01

Time-to-production

De meses de pipeline a semanas de producto. El RAG completo ya está resuelto.

02

Ingesta resuelta

PDFs escaneados, tablas y OCR sin pipeline propio de procesamiento.

03

Seguridad heredada

Permisos por usuario vía IAM de GCP. No construimos esa capa ni la mantenemos.


04

Respuestas con fuente

Grounding y citas nativas: cada respuesta apunta al documento que la sustenta.

Un sistema estacional merece un costo estacional

Estacionalidad de la demanda de matrícula · ciclo 2026



■ Semana de matrícula ■ Resto del ciclo

Vertex gana: 1 asistente, volumen bajo-medio, uso estacional. El MVP sale en semanas.

Pgvector propio gana: N asistentes con volumen alto y sostenido: el costo fijo se amortiza entre todos.

1 Semanas intensas, meses en reposo

El sistema trabaja fuerte durante la matrícula y queda casi inactivo el resto del ciclo.


2 Pay-per-use, no servidores 24/7

Vertex AI Search cobra por consulta e indexación: sin uso, el retrieval no cuesta. Solo queda el contenedor mínimo.

3 La ventaja depende de la escala

Los tokens del LLM se pagan igual en ambas arquitecturas; lo que cambia de lado es el retrieval cuando el volumen crece.

Arquitectura RAG en Cloud Run: Recuperación en Vertex AI Search y auditoría en PostgreSQL



1. **HTTPS / REST** — consulta autenticada al servicio.

4. **Prompt + contexto** — prompt grounded a Gemini.

2. **Retrieval** — búsqueda semántica

5. **Respuesta** — grounded, con citas del contexto.

3. **SQL** — historial y log de auditoría.

6. **Entrega** — respuesta al widget y cacheo.

Hardening



Cloud Sec

- **IAM de mínimo privilegio:** la SA de runtime solo escribe logs y métricas (sin rol Editor); la SA del frontend solo invoca el backend
- **Cloud SQL 100% interno vía VPC egress:** la BD no toca la red pública
- IP estática global + TLS gestionado en el dominio institucional
- Rate limiting por IP en /chat contra abuso y costos descontrolados



AI Safety

- **Firewall semántico** como middleware entre el usuario y el modelo
- **Anti-prompt injection:** bloquea intentos de manipular el system prompt
- **DLP en la salida:** sanitiza nombres de archivos internos y metadatos técnicos antes de responder
- La seguridad de un producto GenAI no termina en la red: también se ataca por el lenguaje

Incidente real: una inconsistencia en la inyección de cabeceras HTTP en /chat rompía el rate limiting. Se detectó en validación, se aplicó el hotfix y se redesplegó. **Probar la capa de defensa es parte del despliegue, no un extra.**

Los números del ciclo completo

9%

sin respuesta

Enseñó más que el 91% atendido: es la hoja de ruta de la siguiente iteración, extraída directamente de los datos.

4,003

consultas atendidas

91%

resueltas por el bot

2.2 s

tiempo promedio

440

consultas el día pico

56%

fuera de horario laboral

Conclusión

El managed service compra tiempo

El pipeline RAG propio es un gran proyecto de ingeniería. Si el negocio pide semanas, no lo construyas: úsalo.

01 Piensa en costo estacional

Para sistemas que viven semanas al año, pay-per-use no es un detalle: es el argumento de negocio.

02 RAG no es cantidad de archivos

Un solo archivo con cientos de Q&A ya es un caso RAG legítimo: importa que la consulta sea impredecible al indexar.

03 Diseñar para aprender

Guardar cada interacción con sus fuentes convierte la atención en datos: la mejora continua sale de ahí.



Gracias

Conectemos

ALAN GARCIA SANCHEZ



PAULO COSTA MONDRAGON

