

Agentes que Prueban agentes

El nuevo paradigma de Quality Engineering en la era de la IA

Alexandra Zamora

Manager
Quality Services


Jefferson Riobueno

Q Lead
Architect






ANTES



Reglas claras
un camino esperado

CAMBIO

AHORA



Comportamiento variable
múltiples caminos válidos



¿Quienes somos?



Alexandra Zamora

Quality Service Manager · NTT DATA

Con más de 15 años de experiencia liderando estrategias de calidad, automatización y equipos de QA en entornos tecnológicos de alto impacto. Actualmente impulsa iniciativas de calidad integradas con IA y DevOps, promoviendo prácticas modernas enfocadas en generar impacto real en productos y equipos tecnológicos.

QUALITY ENGINEERING

IA

DEVOPS

QA STRATEGY



Jefferson Riobueno

Q Lead Architect · NTT DATA

Especialista en calidad de software, DevOps e inteligencia artificial aplicada al ciclo de vida de desarrollo y testing. Actualmente lidera iniciativas de innovación en NTT DATA, enfocadas en la creación de soluciones basadas en IA y en el diseño de estrategias para la evaluación de agentes.

ARCHITECTURE

DEVOPS

AI TESTING

AGENTS



Durante décadas buscamos un **resultado esperado**

```
assertEquals(resultado, esperado)
```





Una pregunta. Tres respuestas. Las tres pueden ser correctas.

“Explícame por qué fue rechazada mi solicitud.”

No cumplió los requisitos mínimos.



No alcanzó los criterios necesarios.



Faltó cumplir las condiciones evaluadas.



¿Cuál es el expected result?



Ya no solo verificamos. **Evaluamos.**

ANTES

`expected == actual`

AHORA

`quality_score ≥
threshold`

El agente no estaba fallando. **Nuestra forma de probarlo sí.**

Medir calidad fue solo el **primer paso**



Relevancia

Faithfulness

Coherencia

Alucinación

Seguridad

01

¿Quién crea los escenarios?

GENERADOR

02

¿Quién simula al usuario?

USUARIO SINTÉTICO

03

¿Quién decide si es buena?

JUEZ

04

¿Quién intenta romperlo?

RED TEAM



¿QUIÉN PRUEBA A LOS AGENTES?



OTROS AGENTES.



GENERADOR

Crea escenarios



USUARIO

Simula comportamiento



JUEZ

Evalúa respuestas



RED TEAM

Busca vulnerabilidades



No genera preguntas. **Genera escenarios con intención.**

MÉTRICA A ESTRESAR

CONTEXTO

RAG / DOCUMENTOS

PERSONA

HISTORIAL

**AGENTE
GENERADOR**


ESCENARIOS DE PRUEBA

100 preguntas ≠ 100 buenos tests

**Diseñados para encontrar
problemas.**



El test case dejó de ser una pregunta. **Ahora puede ser una conversación.**



SOFÍA

frustración ↑

paciencia .3

nivel bajo

typos

no nativo

Prueba restableciendo tu contraseña...

no puedo entrar

YA HICE ESO Y NO FUNCIONA

Entiendo. Revisemos otra opción...

bueno y si cambié de teléfono?



No pregunta si es igual. **Pregunta si es suficientemente bueno.**

RESPUESTA + CRITERIO

IA → evalúa → IA



LLM-AS-A-JUDGE

0.87

THRESHOLD 0.70



La calidad de un agente no es un número. Es un perfil.


~74

métricas · 7 dimensiones

Calidad de respuesta · Seguridad/OWASP · Conversación · RAG · Estilo · Comportamiento agéntico · Rendimiento

Mismo score global.

Perfil de riesgo distinto.





No evaluamos un solo tipo de agente. Evaluamos **distintos patrones agénticos**.



Agentes conversacionales

CONVERSAR


Contexto, memoria, coherencia, tono y seguridad en diálogos multi-turn.



Agentes orientados a tareas

EJECUTAR

Planificación, uso de herramientas, cumplimiento del objetivo y recuperación ante fallos.



RAG agéntico

FUNDAMENTAR

Retrieval, grounding, selección de fuentes, faithfulness y decisiones basadas en contexto.



Sistemas multi-agente

COLABORAR

Coordinación, hand-offs, roles, consistencia y resultado colectivo.



Orquestadores

COORDINAR

Routing, delegación, secuencia, control del flujo y trazabilidad del proceso.

La estrategia de evaluación cambia según cómo el sistema **razona, actúa y colabora**.



No le preguntamos si es seguro. **Intentamos romperlo.**



8 familias · hasta 500 ataques por campaña · variantes dinámicas



Cuando juntamos todo, dejamos de tener una **colección de tests**





Ya no es un experimento. **Es una capacidad.**

~74

métricas

8

familias de ataque

500

ataques por campaña

MULTI-
TURN

evaluaciones

Generación dinámica de datasets · usuarios sintéticos · trazabilidad



Para funcionar de verdad, **no podía quedarse en un notebook**



Distribuido · especializado · escalable horizontalmente · trazable



Después de construirlo, tres cosas cambiaron nuestra forma de pensar **QA**

01

QA ES PROBABILÍSTICO

scores · thresholds · distribuciones · variabilidad

02

CALIDAD ES MULTIDIMENSIONAL

“funciona / no funciona” ya no alcanza

03

EL TESTING TAMBIÉN PUEDE RAZONAR

generar · simular · evaluar · atacar



**Cuando el sistema que
construimos se vuelve más
inteligente...**





**Cuando el sistema que
construimos se vuelve más
inteligente...**

**la forma en la que aseguramos su
calidad también tiene que
evolucionar.**





**Cuando el sistema que
construimos se vuelve más
inteligente...**

**la forma en la que aseguramos su
calidad también tiene que
evolucionar.**

AGENTES
QUE PRUEBAN
AGENTES

A faint, stylized illustration of a hummingbird in flight, positioned behind the text "QUE PRUEBAN".



Gracias Conectemos

Escanea los códigos para
contactarnos



Alexandra Zamora



Jefferson Riobueno